

TREINAMENTO DE MODELOS NERF BASEADOS EM GRID: UM OLHAR PARA O CONSUMO DE VRAM E OTIMIZAÇÃO DE HIPERPARÂMETROS EM HARDWARES DE BAIXA ESPECIFICAÇÃO

TRAINING GRID-BASED NERF MODELS: A LOOK AT VRAM CONSUMPTION AND HYPERPARAMETER OPTIMIZATION ON LOW-SPEC HARDWARE

Luis Afonso Mineo¹
Gustavo Queiroz Silveira²

RESUMO

Os Campos de Radiância Neural (*Neural Radiance Fields*, NeRF) possibilitam a síntese de novas vistas com elevada fidelidade visual, porém seu treinamento permanece dependente de recursos computacionais significativos, especialmente memória de vídeo. Arquiteturas baseadas em grade, como o Instant-NGP, reduziram substancialmente o tempo de treinamento por meio de uma codificação hash multirresolução, mas sua aplicação em GPUs com capacidade limitada de VRAM ainda é pouco caracterizada. Este trabalho investiga o impacto dos hiperparâmetros *log2_hashmap_size*, *n_features_per_level* e *n_levels* sobre a qualidade de reconstrução, o consumo de memória e o tempo de treinamento do Instant-NGP em uma GPU de consumo com 6 GB de VRAM. Os experimentos foram conduzidos nas cenas Garden e Bonsai do conjunto Mip-NeRF 360, utilizando busca em grade e avaliação por PSNR, SSIM, LPIPS, pico de VRAM e tempo de treinamento, seguida de análise multiobjetivo por Fronteira de Pareto. Os resultados mostram que a redução dos hiperparâmetros da codificação pode produzir configurações mais eficientes com degradação limitada de qualidade; entretanto, seu efeito sobre o pico total de VRAM não é proporcional ao tamanho da estrutura hash. Verificou-se que uma parcela significativa da memória é determinada pelo armazenamento das imagens de treinamento e por alocações dinâmicas do processo de amostragem, estabelecendo um piso de consumo independente dos hiperparâmetros analisados. Dessa forma, a viabilidade do treinamento em hardware restrito depende não apenas da configuração do modelo, mas também da resolução, do conjunto de dados e do comportamento do ambiente de execução. O estudo contribui com uma caracterização experimental dos limites e dos trade-offs envolvidos na otimização do Instant-NGP em hardware de baixa especificação.

Palavras-chave: campos de radiância neural; Instant-NGP; otimização de hiperparâmetros; memória de vídeo; hardware de baixa especificação; síntese de novas vistas.

¹ Graduando do Curso de Ciência da Computação do Centro Universitário Filadélfia - UniFil. luismineo@edu.unifil.br

² Orientador: Professor Esp. do curso de Ciência da Computação do Centro Universitário Filadélfia - UniFil. gustavo.silveira@unifil.br

ABSTRACT

Neural Radiance Fields (NeRFs) enable high-fidelity novel view synthesis, but their training still requires substantial computational resources, particularly video memory. Grid-based architectures such as Instant-NGP have greatly reduced training time through multiresolution hash encoding; however, their behavior on GPUs with limited VRAM remains insufficiently characterized. This work investigates the impact of the `log2_hashmap_size`, `n_features_per_level`, and `n_levels` hyperparameters on reconstruction quality, memory consumption, and training time of Instant-NGP on a consumer-grade GPU with 6 GB of VRAM. Experiments were conducted on the Garden and Bonsai scenes from the Mip-NeRF 360 dataset using a grid search evaluated through PSNR, SSIM, LPIPS, peak VRAM usage, and training time, followed by a Pareto-based multi-objective analysis. The results show that reducing hash-encoding hyperparameters can yield more efficient configurations with limited degradation in reconstruction quality; however, their effect on total peak VRAM is not proportional to the size of the hash representation. A significant portion of memory consumption was found to be determined by the storage of training images and by dynamic allocations related to the sampling process, establishing a memory floor that is independent of the analyzed hyperparameters. Therefore, training feasibility on constrained hardware depends not only on model configuration, but also on image resolution, dataset characteristics, and runtime behavior. This study provides an experimental characterization of the limits and trade-offs involved in optimizing Instant-NGP for low-specification hardware.

Keywords: neural radiance fields; Instant-NGP; hyperparameter optimization; video memory; low-specification hardware; novel view synthesis.

1 INTRODUÇÃO

O advento da técnica de síntese de novas vistas, possibilitada pela criação do modelo NeRF (*Neural Radiance Fields*) (Mildenhall et al., 2021), abriu um novo leque de possibilidades para a representação de cenas tridimensionais. Porém, um dos principais impeditivos para a popularização da técnica entre hobbistas e pesquisadores é o preço proibitivo do hardware necessário para o treinamento do modelo, em especial as placas de vídeo.

A síntese de novas vistas consiste em gerar imagens de uma cena a partir de perspectivas não capturadas originalmente, tendo como entrada apenas um conjunto de fotografias bidimensionais com posições de câmera conhecidas. Abordagens anteriores dependiam de amostragem densa de imagens e de representações geométricas explícitas (malhas poligonais, voxels ou nuvens de

pontos), apresentando limitações ao lidar com reflexos, oclusões e superfícies de topologia complexa (Liao et al., 2025). O NeRF substitui essa geometria explícita por uma representação implícita e contínua, codificada nos próprios pesos de uma rede neural, que mapeia coordenadas espaciais e direções de visão (uma entrada de cinco dimensões, ou 5D) diretamente em cor e densidade volumétrica. A imagem final é sintetizada por renderização volumétrica diferenciável, acumulando cor e opacidade ao longo dos raios de visão (Mildenhall et al., 2021; Gao et al., 2026).

Os modelos NeRF utilizam-se de *Multilayer Perceptrons* (MLPs) para o treinamento e renderização das cenas, e para tal, realizam diversos cálculos matriciais, os quais são fortemente dependentes de processamento paralelo (Goodfellow; Bengio; Courville, 2016). As placas de vídeo modernas são altamente especializadas neste tipo de cálculo, além de diversas bibliotecas, como TensorFlow, que foram otimizadas para utilizar este hardware em suas operações (Abadi et al., 2016). Essas redes são treinadas pela minimização de uma função de perda fotométrica, com ajuste iterativo dos pesos por meio do algoritmo de retropropagação em conjunto com otimizadores de gradiente, como o Adam (Kingma; Ba, 2014). Um obstáculo adicional é o viés espectral (*spectral bias*), a tendência de redes neurais aprenderem funções de baixa frequência mais rapidamente do que detalhes finos. O NeRF original contorna essa limitação por meio da codificação posicional com funções de Fourier, que projeta as coordenadas de entrada em um espaço de alta dimensionalidade e viabiliza a captura de alta frequência (Tancik et al., 2020).

Para contornar o longo tempo de processamento exigido pelo modelo original, a indústria e a pesquisa recente migraram para arquiteturas baseadas em grade (Liao et al., 2025). Nessas novas abordagens, as características da cena passam a ser armazenadas explicitamente em estruturas de dados, como tabelas de hash ou voxels (Gao et al., 2026; Shin; Park, 2023). Essa mudança de paradigma tira grande parte da carga de memorização do modelo, permitindo o uso de MLPs bem menores e mais rápidas para calcular as cores e a densidade da imagem (Shin; Park, 2023). Nessas arquiteturas híbridas, a MLP é reduzida a um decodificador mais compacto, essa estratégia, por sua vez, acelerou a convergência de horas para minutos em modelos como Plenoxels (Fridovich-Keil et al., 2022), DVGO (Sun et al.,

2022), TensoRF (Chen et al., 2022) e K-Planes (Fridovich-Keil et al., 2023), com resultados superiores a 31 dB de PSNR (*Peak Signal-to-Noise Ratio*, ou Relação Sinal-Ruído de Pico, em português) no *dataset* (conjunto de imagens e posições de câmera, neste contexto) Synthetic-NeRF (Gao et al., 2026). O *Instant-NGP* (Müller et al., 2022) representa o estado da arte entre esses modelos, no quesito de velocidade, alcançando 33,18 dB em aproximadamente cinco minutos, uma aceleração de até sessenta vezes sobre o NeRF original. Todos esses avanços, contudo, foram avaliados em GPUs (*Graphics Processing Unit*, ou Unidade de Processamento Gráfico, em português) de alto desempenho, como a RTX 3090 de 24 GB utilizada nos experimentos originais do Instant-NGP, deixando em aberto a viabilidade dessas arquiteturas em hardware de consumo padrão, como em GPUs com 6 GB de VRAM (*Video Random Access Memory*, ou memória de acesso aleatório de vídeo, em português).

Entretanto, essa evolução introduz novos custos de memória. Nas arquiteturas baseadas em grade, parte da representação da cena passa a ser armazenada explicitamente em estruturas auxiliares, tornando a capacidade de memória de vídeo (VRAM) um fator relevante durante o treinamento (Shin; Park, 2023). Em GPUs com capacidade limitada, o consumo combinado pela representação do modelo, pelos dados de treinamento e pelas demais estruturas mantidas durante a otimização pode restringir a resolução ou a complexidade das cenas processadas, chegando, em determinadas condições, a inviabilizar a execução por insuficiência de memória (Liao et al., 2025).

Cabe notar que a literatura de eficiência para NeRF concentra-se majoritariamente na redução de custo durante a inferência, por meio de técnicas como *baking* e super-resolução (Gao et al., 2026; Lin et al., 2024), e não durante o treinamento. Liao et al. (2025) reforçam essa observação ao indicar que o pico de alocação de VRAM na fase de otimização permanece pouco explorado, justamente o ponto em que GPUs mais modestas inviabilizam a execução antes mesmo de produzir qualquer imagem renderizada em *datasets* maiores.

É nesse contexto que se insere este trabalho. O estudo investiga o treinamento do *Instant-NGP* em uma GPU de consumo com capacidade limitada de VRAM, buscando caracterizar como diferentes componentes do processo

contribuem para o custo de memória e em que medida os hiperparâmetros da codificação hash podem modificar esse consumo. Para isso, são avaliados os efeitos de diferentes configurações sobre a qualidade de reconstrução, o pico de VRAM e o tempo de treinamento, permitindo identificar os compromissos entre fidelidade visual e custo computacional. O objetivo é, assim, caracterizar tanto o potencial quanto os limites da otimização de hiperparâmetros como estratégia para a execução do Instant-NGP em hardware de baixa especificação.

O modelo adotado neste trabalho, o *Instant-NGP* (Müller et al., 2022), substitui a codificação posicional de Fourier por uma hierarquia de tabelas de hash de tamanho fixo distribuídas em diferentes níveis de resolução espacial. O método mapeia coordenadas 3D, aplica uma função de hash para acessar vetores de características locais, interpola esses valores e concatena o resultado para alimentar uma MLP compacta. As colisões de hash não são tratadas explicitamente: cabe à própria rede desambiguar os pontos sobrepostos, o que se torna viável graças à redundância entre os múltiplos níveis de resolução. Associada a uma implementação em kernels CUDA altamente otimizados (*tiny-cuda-nn*), essa estrutura atinge qualidade foto realista comparável à do NeRF original em poucos minutos (Müller et al., 2022). Essa estrutura acrescenta ao treinamento uma parcela de memória associada à codificação hash multirresolução. Parâmetros como o tamanho máximo das tabelas de hash, a dimensão dos vetores de características e o número de níveis determinam a capacidade dessa representação e, conseqüentemente, influenciam sua alocação de memória. O impacto dessas variáveis sobre o pico total de VRAM, entretanto, deve ser considerado em conjunto com outros componentes do treinamento, como o armazenamento das imagens e as alocações dinâmicas realizadas durante o processo de amostragem. Dessa forma, embora a redução desses hiperparâmetros diminua a capacidade teórica da estrutura de codificação, podemos tentar determinar experimentalmente, em que grau essa redução se traduz em economia no consumo total de VRAM e qual o custo correspondente em qualidade.


A escolha do *Instant-NGP* como objeto de estudo deste trabalho tem uma observação importante. Desde 2023, o *Gaussian Splatting* Tridimensional (3DGS), introduzido por Kerbl et al. (2023), tornou-se o paradigma dominante para síntese de

novas vistas, superando os modelos NeRF em velocidade de renderização e em qualidade visual (Gao et al., 2026). Sua representação é explícita, ou seja, a cena é descrita por um conjunto de primitivas gaussianas 3D que são projetadas no plano da imagem e ordenadas por profundidade em um processo de rasterização denominado *splatting*, dispensando o *ray marching* volumétrico dos NeRFs. O ganho de velocidade, todavia, vem acompanhado de requisitos de VRAM e de armazenamento consideravelmente maiores (Gao et al., 2026), restrições ainda mais severas no hardware de 6 GB considerado nesta pesquisa. Por esse motivo, optou-se pelo modelo híbrido baseado em grade.

2 PRELIMINARES E DEFINIÇÃO DO CENÁRIO

Inicialmente o trabalho esperava analisar apenas os datasets Lego e Chair, por serem amplamente utilizados na literatura e possuírem características dissidentes, o que, assumia-se ser o suficiente para identificar os valores paramétrais relevantes a ambos os extremos do espectro de cenas. Dado essa premissa, foi realizado o experimento *exp01*, o qual, os resultados, que podem ser vistos na Figura 1 abaixo, demonstraram que o *Instant-NGP* já se demonstra otimizado, para *datasets* pequenos. Portanto, a fim de continuar com a experimentação e expandir a busca para *datasets* maiores, os autores decidiram por usar o *dataset Garden*, este, também, amplamente utilizado e considerado padrão ouro na literatura (Gao et al., 2026), inicialmente apresentado através do artigo do *Mip-NeRF 360* (Barron, et al. 2021). *Mip-NeRF 360* reúne cenas reais não-limitadas (*unbounded*), nas quais a câmera circunda um objeto central e o conteúdo de fundo se estende a distâncias mais arbitrárias (Barron et al., 2022). Essa característica amplia a região do espaço que precisa ser amostrada e representada pela estrutura de grade, aumentando assim a pressão sobre a placa de vídeo. A cena *Garden*, especificamente, apresenta geometria complexa e folhagem de alta frequência, o que dificulta a inferência do modelo e acarreta maior consumo de VRAM.

Figura 1 – Gráfico de PSNR por VRAM para o experimento inicial



Fonte: Elaborado pelos autores (2026).

No exp01, o pico de VRAM não ultrapassou 2981 MB em nenhuma das 54 execuções, e nenhuma falhou por falta de memória, portanto o conjunto *Synthetic-NeRF* não exerce pressão sobre uma GPU de 6 GB.

Adicionalmente, a fim de possibilitar uma análise comparativa entre cenas de perfis distintos, mantendo a mesma lógica de contraste geométrico empregada no experimento *exp01* entre as cenas Lego e Chair, optou-se por incluir uma segunda cena do mesmo *dataset Mip-NeRF 360*: o Bonsai, um ambiente interno, de menor extensão espacial e geometria mais regular, em contraposição à cena externa e complexa do Garden.

Diferentemente do *Synthetic-NeRF*, contudo, o *dataset Mip-NeRF 360* disponibiliza cada cena em múltiplas resoluções, reduções por fatores de 2, 4 e 8 em relação à resolução original de captura, sem indicar previamente qual delas seria adequada aos propósitos desta pesquisa. Escolher uma resolução arbitrariamente acarretaria no mesmo risco metodológico já identificado no exp01: uma resolução baixa demais poderia novamente não pressionar os 6 GB de VRAM disponíveis, reproduzindo o efeito de teto observado anteriormente; uma resolução alta demais, por sua vez, poderia levar todas as combinações de hiperparâmetros a falhar por

esgotamento de memória, inviabilizando a construção da fronteira de Pareto. Fez-se necessária, portanto, uma etapa de calibração prévia à execução do experimento principal.

Essa calibração consistiu em treinar o *Instant-NGP* em sua configuração padrão, sem variação dos hiperparâmetros de codificação de hash, para cada uma das resoluções disponíveis de cada cena, por um número reduzido de iterações, suficiente apenas para que o pico de alocação de memória fosse atingido. O pico de VRAM de cada execução foi registrado e comparado ao limite físico da GPU utilizada (RTX 2060, 6GB), conforme apresentado na Tabela 1 abaixo. O critério adotado para a escolha da resolução definitiva de cada cena foi selecionar a menor resolução (maior fator de redução) cujo consumo se aproximasse do limite de 6 GB, ou, alternativamente, a resolução imediatamente anterior à primeira ocorrência de falha por falta de memória.

Tabela 1 - Experimento 02 para escolha de resolução

Cena	Fator de Escala	Resolução	Qtd. Imagens	Status	Pico de VRAM (MB)	VRAM Base (MB)	VRAM do Dispositivo (MB)	VRAM na Falha (MB)
garden	8	648x420	185	OK	3477,6	438,6	3916,2	-
garden	4	1297x840	185	OK	4952,6	447,6	5400,2	-
garden	2	2594x1681	185	OOM	4462,6	447,6	4910,2	5918,2
garden	1	-	-	Pulado	-	-	-	-
bonsai	8	390x260	292	OK	2958,6	447,6	3406,2	-
bonsai	4	780x520	292	OK	3906,6	447,6	4354,2	-
bonsai	2	1559x1039	292	OK	5604,6	447,6	6052,2	-
bonsai	1	3118x2078	292	OOM	5546,6	447,6	5994,2	5921,7

Fonte: Elaborado pelos autores, 2026

Paralelamente, foi necessário determinar o valor do parâmetro *aabb_scale* para cada cena. Esse parâmetro define a extensão espacial da caixa dentro da qual o modelo assume que toda a cena pode ser representada, sendo estruturado como uma cascata de grades de ocupação multiescala (Müller et al., 2022). Diferentemente do *Synthetic-NeRF*, cujas cenas são objetos isolados contidos em um cubo unitário (*aabb_scale* = 1), cenas reais e não-limitadas, como as do

Mip-NeRF 360, exigem valores mais altos, de modo a acomodar elementos de fundo que se estendem além do objeto central, caso contrário, o modelo tende a alucinar e renderizar *floaters* (artefatos visuais “flutuantes”) nas bordas da caixa. A documentação oficial da implementação orienta que o valor seja sempre uma potência de dois e recomenda, para cenas naturais, que se inicie a partir de um valor elevado e reduza-o progressivamente por fatores de dois até que a qualidade da reconstrução seja considerada adequada (NVLABS, 2025). Seguindo essa orientação, ambas as cenas foram inicialmente configuradas com *aabb_scale* = 16, sendo então submetidas a uma verificação empírica: treinamentos breves foram realizados para valores candidatos, com inspeção das imagens renderizadas em busca de artefatos característicos de uma caixa delimitadora subdimensionada, manchas ou névoa próximas às bordas da reconstrução, indicando conteúdo de fundo não contemplado pela caixa, além da verificação mais objetiva por cálculo de *PSNR*. Os resultados dessa verificação estão descritos na Seção 2.1, e determinaram o valor de *aabb_scale* efetivamente utilizado na etapa seguinte do experimento.

2.1 CALIBRAÇÃO DO DATASET

A calibração do fator *aabb_scale* foi realizada através de uma verificação visual dos resultados, além da verificação mais objetiva por cálculo do *PSNR*, métrica que relaciona o valor máximo possível de um pixel ao erro quadrático médio da reconstrução e que constitui o padrão consolidado de avaliação de fidelidade de imagem (Wang et al., 2004). Na Figura 2, abaixo, podemos notar que o fator 4 e 8 são os melhores candidatos visuais.


Figura 2 – Comparação visual da cena *Garden* para fatores de 2 a 32



Fonte: Elaborado pelos autores (2026).

Como podemos notar, o fator 2 e 16 apresentam diversos artefatos neste ângulo, que prejudicam a visualização da cena, o que, curiosamente, contradiz a recomendação inicial dos autores do *Instant-NGP*. Essa rodada de testes, também capturou os valores de *PSNR* e revelou que, o fator 4 se confirma como o melhor candidato através do cálculo de fidelidade visual, ainda mantendo um pico de alocação de memória baixo, observado na Figura 3.

Figura 3 – Gráfico comparativo para o fato de *aabb_scale*



Fonte: Elaborado pelos autores (2026).

3 METODOLOGIA

Após a escolha e calibragem do novo dataset, partimos para a experimentação em si. O experimento deste trabalho estrutura-se em 4 etapas: a definição do baseline, a exploração sistemática de hiperparâmetros, a análise multiobjetivo dos resultados e, por fim, a avaliação das métricas encontradas. A lógica que organiza essas etapas é a de estabelecer primeiro um limite superior de qualidade (o comportamento do modelo em sua configuração padrão) e, a partir dele, medir o quanto de memória é possível economizar e qual o custo disso em fidelidade visual. Esta seção descreve o ambiente experimental e detalha cada uma das etapas.

3.1 AMBIENTE EXPERIMENTAL

O ambiente utilizado para este experimento foi uma GPU Nvidia RTX 2060 com 6GB de memória de vídeo (VRAM), uma CPU Ryzen 7 5700 X3D e 16 GB de RAM DDR4, tudo executado dentro de um ambiente WSL (*Windows Subsystem for Linux*) com ubuntu.

3.2 DEFINIÇÃO DO BASELINE


O baseline consiste no treinamento do Instant-NGP em sua configuração padrão, arquivo de rede (*base.json*) sem qualquer alteração nos hiperparâmetros de codificação de hash (Müller et al., 2022), aplicado a cada uma das duas cenas, na resolução e no *aabb_scale* definidos na etapa de calibração (Seção 2.1). Para a cena Garden, adotou-se o fator de redução 2 (2594×1681 pixels) e *aabb_scale* = 4; para a cena Bonsai, adotou-se o fator de redução 2 (1559×1039 pixels) e *aabb_scale* = 8, seguindo o mesmo critério de seleção descrito na Seção 2.

Diferentemente do *exp01*, no qual o dataset Synthetic-NeRF já disponibiliza uma divisão oficial entre conjuntos de treino e teste, o dataset Mip-NeRF 360 não oferece tal separação. Adotou-se, portanto, a convenção consolidada na literatura para cenas reais, na qual uma a cada oito imagens é reservada para o conjunto de teste e as demais compõem o conjunto de treino, procedimento estabelecido no LLFF (Mildenhall et al., 2019) e mantido na avaliação do próprio *Mip-NeRF* 360 (Barron et al., 2022), regra assim, aplicada de forma idêntica a todas as execuções de ambas as cenas. Com essa regra, Garden passou a contar com 161 imagens de treino e 24 de teste, e Bonsai com 255 e 37. Todas as métricas de qualidade deste trabalho foram calculadas sobre as vistas retidas.. Por se tratar de cenas não-limitadas, desabilitou-se também o modo de compatibilidade com o protocolo do NeRF original (*nerf_compatibility*), adequado ao Synthetic-NeRF mas não aos datasets reais utilizados nesta etapa.

Para determinar um novo número de iterações de treinamento foi realizado uma nova execução de uma validação específica da curva de convergência para cenas não-limitadas, disponível na Figura 4 abaixo, em procedimento análogo ao realizado para a cena Lego no projeto original. A verificação fez-se necessária porque cenas reais tendem a apresentar uma convergência mais lenta do que cenas sintéticas, tornando inadequada a reutilização direta do número de iterações anteriormente adotado. Vale lembrar que, na implementação original, o marco de 20.000 passos corresponde ao ponto em que ocorre a primeira penalização da taxa de aprendizado (*learning rate decay*), o que o torna um ponto de parada metodologicamente defensável desde que sustentado pela curva de perda observada (Müller et al., 2022).

Figura 4 – Curva de convergência que justifica número de iterações

Escolha do numero de iterações — bonsai f2 (1559x1039), aabb_scale=8
vermelho tracejado: 5000 iterações (escolhido) | custo por execução = treino + 55s aval + 12s setup



Fonte: Elaborado pelos autores (2026).

A análise da curva de convergência indica que o modelo continua apresentando ganhos de qualidade após 5.000 iterações, atingindo uma região de maior estabilização aproximadamente a partir de 10.000 iterações, quando o ganho marginal de PSNR cai para valores próximos ou inferiores a 0,1 dB por 1.000 iterações. Entretanto, como o objetivo desta etapa não é obter a máxima qualidade possível para uma única configuração, mas comparar sistematicamente as 27 combinações do Grid Search sob um mesmo orçamento computacional, adotaram-se 5.000 iterações como ponto de compromisso entre maturidade do treinamento e custo experimental. Nesse ponto, a maior queda da função de perda já ocorreu e as métricas de qualidade encontram-se em trajetória de estabilização, enquanto extensões do treinamento aumentariam substancialmente o custo total do experimento. Dessa forma, as 5.000 iterações devem ser interpretadas como um orçamento experimental padronizado, e não como o ponto de convergência completa do modelo. O objetivo desta etapa foi estabelecer esse limite superior de

qualidade visual e um ponto de referência de custo computacional para cada cena, contra os quais as configurações exploradas na etapa seguinte serão comparadas.

3.3 EXPLORAÇÃO SISTEMÁTICA DOS HIPERPARÂMETROS

Na etapa seguinte, aplicou-se novamente o método de Busca em Grade (Grid Search) já empregado no exp01, mantendo o mesmo espaço de busca sobre os três hiperparâmetros da codificação de hash multirresolução: $\log_2_hashmap_size$ (T) $\in \{15, 17, 19\}$, $n_features_per_level$ (F) $\in \{2, 4, 8\}$ e n_levels (L) $\in \{4, 8, 16\}$, totalizando 27 combinações por cena. A escolha da Busca em Grade justifica-se pelas características do espaço explorado. Bergstra e Bengio (2012), ao proporem a busca aleatória como alternativa, reconhecem que o *Grid Search* permanece confiável em espaços de baixa dimensionalidade e que, em espaços reduzidos com execução sequencial, pode superar o *Random Search*. Com apenas três hiperparâmetros e 27 combinações por cena, o espaço desta pesquisa enquadra-se nesse campo favorável, somando-se a isso a garantia de cobertura completa e de reprodutibilidade do experimento.

A resolução e o *aabb_scale* de cada cena permaneceram fixos nos valores definidos na etapa de calibração e replicados na definição do baseline (Seção 3.2), variando-se exclusivamente os três hiperparâmetros de codificação. Estes, por sua vez, atuam diretamente sobre o volume de memória alocado pela codificação de hash. O expoente do tamanho máximo de cada tabela (T), a dimensão do vetor de características armazenado em cada entrada (F) e o número de níveis de resolução (L) determinam o limite superior do número de parâmetros da estrutura de grade, proporcional a $L \cdot 2^T \cdot F$ (Müller et al., 2022); reduções em qualquer um dos três implicam, portanto, redução proporcional no consumo de VRAM. Müller et al. (2022) fixam $L = 16$, $T = 19$ e $F = 2$ como configuração padrão, valores que correspondem exatamente ao vértice superior do espaço de busca aqui adotado e, consequentemente, ao *baseline* descrito na Seção 3.2.

A manutenção do mesmo espaço de busca do exp01 é proposital, pois permite que os efeitos observados em cada hiperparâmetro sejam comparáveis, em relativamente, entre a de cena limitada (*Synthetic-NeRF*) e o de cena não-limitada

(*Mip-NeRF 360*), ainda que os valores absolutos de PSNR não sejam diretamente comparáveis entre os dois experimentos, dado que os protocolos de avaliação, a divisão de dados e a natureza das cenas diferem.

Para cada combinação, foram registradas as mesmas cinco métricas coletadas no *exp01*: PSNR, SSIM e LPIPS, como medidas de qualidade de reconstrução visual, e pico de alocação de VRAM e tempo de treinamento, como medidas de custo computacional. Diferentemente do *exp01*, no qual nenhuma das 54 execuções resultou em falha por falta de memória, esperava-se, dada a calibração realizada na Seção 2, que uma parcela das combinações desta etapa pudesse exceder os 6 GB de VRAM disponíveis. Execuções nessas condições não foram descartadas: o status de cada execução foi registrado como resultado válido, uma vez que o mapeamento das combinações inviáveis representam uma informação relevante para a análise multiobjetivo subsequente.

3.4 ANÁLISE MULTIOBJETIVO DOS RESULTADOS

A Fronteira de Pareto é o instrumento consolidado da otimização multiobjetivo para mapear permutas (*trade-offs*) entre critérios conflitantes. Assumimos que uma configuração domina outra quando é ao menos tão boa em todos os objetivos e estritamente melhor em pelo menos um deles; o conjunto das soluções não dominadas define a fronteira na qual qualquer ganho em um objetivo implica necessariamente sacrifício em outro (Deb, 2011). A vantagem dessa abordagem, no contexto desta pesquisa, é permitir a identificação do ponto de equilíbrio (*sweet spot*) entre fidelidade visual e custo computacional sem que seja preciso arbitrar previamente uma ponderação entre os critérios.

Os resultados do Grid Search completo foram submetidos à mesma análise multiobjetivo fundamentada na Fronteira de Pareto empregada no *exp01*, na qual uma configuração é considerada não dominada quando nenhuma outra configuração é simultaneamente igual ou superior em todos os objetivos e estritamente superior em ao menos um deles. Os três objetivos considerados foram: maximizar o PSNR, minimizar o pico de alocação de VRAM e minimizar o tempo de treinamento.

A fronteira foi calculada separadamente para cada cena, permitindo avaliar se as configurações identificadas como não dominadas se sustentam em perfis de cena distintos, um externo, com vegetação e geometria complexa, e outro interno, com geometria mais regular e menor extensão espacial (*Garden* e *Bonsai*, respectivamente), na mesma lógica de validação externa empregada entre as cenas Lego e Chair no *exp01*.

Optou-se por apresentar como resultado principal a projeção bidimensional entre PSNR e pico de VRAM, e não a fronteira tridimensional completa. Essa escolha decorre da observação, já registrada no *exp01*, de que a fronteira tridimensional tende a ser pouco clara, quando os três objetivos são considerados simultaneamente, ao passo que a projeção bidimensional evidencia com mais clareza o comportamento entre qualidade visual e custo de memória.

3.5 AVALIAÇÃO DAS MÉTRICAS

A avaliação comparativa entre o baseline e as configurações do Grid Search seguiu a mesma estrutura de duas categorias adotada no *exp01*. Para o custo computacional, foram registrados o pico de alocação de VRAM, em megabytes, e o tempo total de treinamento, em segundos. Para a qualidade de reconstrução visual, empregaram-se as três métricas complementares já utilizadas anteriormente: o PSNR, medido em decibéis, que relaciona o valor máximo possível de um pixel ao erro quadrático médio (MSE) da reconstrução e é amplamente adotado por sua simplicidade de cálculo e por suas propriedades matemáticas bem definidas, ainda que não reflita perfeitamente a percepção visual humana, imagens com o mesmo PSNR podem apresentar qualidades perceptuais distintas (Wang et al., 2004); o SSIM, que avalia a imagem a partir de luminância, contraste e estrutura, capturando texturas e bordas de forma mais alinhada à percepção humana e sendo particularmente sensível a desfoque e a artefatos como *floaters* e perda de nitidez (Wang et al., 2004); e o LPIPS, calculado com a rede *AlexNet*, que compara imagens por meio das representações internas de redes neurais pré-treinadas, partindo da ideia de que essas redes capturam padrões perceptuais inacessíveis a métricas calculadas apenas sobre pixels (Zhang et al., 2018). Diferentemente das

duas primeiras, o LPIPS é uma métrica de distância, na qual valores menores indicam maior similaridade, o que o torna eficaz para detectar artefatos de alta frequência, como o ruído granular produzido por colisões de hash. O uso conjunto das três (fidelidade global, estrutura local e similaridade perceptual) é uma prática consolidada na literatura de NeRF (Mildenhall et al., 2021) e garante uma avaliação mais completa do que qualquer uma delas isoladamente.

A degradação de cada configuração em relação ao respectivo baseline foi expressa em variação percentual de VRAM e tempo de treinamento, e em variação absoluta de PSNR (em decibéis), permitindo identificar, para cada cena, o conjunto de configurações cuja degradação de qualidade permaneceu dentro do limiar de -2 dB considerado aceitável na literatura (Mildenhall et al., 2021; Müller et al., 2022). Os resultados dessa avaliação, incluindo a comparação entre os regimes de cena limitada e não-limitada quanto à magnitude dos efeitos observados para cada hiperparâmetro, são apresentados e discutidos na Seção 4.

4 ANÁLISE DOS RESULTADOS

Os resultados desta etapa, para as cenas Garden e Bonsai, estão apresentados na Tabela Y e na Figura X.

<TODO - Inserir Tabela com resultados do grid>

<TODO - Inserir Figura com curva de convergência>

<TODO>

5 CONCLUSÃO

<TODO>

REFERÊNCIAS

- DEB, Kalyanmoy. **Multi-objective optimization using evolutionary algorithms: an introduction**. Kanpur: Indian Institute of Technology Kanpur, 2011. (KanGAL Report Number 2011003).
- DESCARTES, René. **Discurso do método**. Tradução de Maria Ermantina Galvão. 2. ed. São Paulo: Martins Fontes, 2001.
- FOLEY, James D. et al. **Computer graphics: principles and practice**. 2nd ed. Reading: Addison-Wesley, 1996.
- FRIDOVICH-KEIL, Sara et al. **K-Planes: Explicit radiance fields in space, time, and appearance**. arXiv:2301.10241, 2023.
- FRIDOVICH-KEIL, Sara et al. **Plenoxels: Radiance fields without neural networks**. In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2022.
- GAO, Kyle et al. **NeRF: Neural radiance field in 3D vision, a comprehensive review**. Computational Visual Media, [S. l.], 2026.
- GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep learning**. Cambridge: MIT Press, 2016.
- KERBL, Bernhard et al. **3D Gaussian Splatting for real-time radiance field rendering**. ACM Transactions on Graphics, v. 42, n. 4, p. 193:1–193:14, 2023.
- KINGMA, Diederik P.; BA, Jimmy. Adam: **A method for stochastic optimization**. arXiv:1412.6980, 2014.
- LIAO, Yun et al. **A survey on neural radiance fields**. ACM Computing Surveys, [S. l.], v. 58, n. 2, 2025.
- LIN, Chen-Yu et al. **FastSR-NeRF: improving NeRF efficiency on consumer devices with a simple super-resolution pipeline**. In: IEEE/CVF WINTER CONFERENCE ON APPLICATIONS OF COMPUTER VISION, 2024. p. 6036–6045.
- MILDENHALL, B; SRINIVASAN, P.; TANI, M.; BARRON, J.; RAMAMOORTHY, R.; NG, R.. **NeRF: representing scenes as neural radiance fields for view synthesis**. Commun. ACM, v.65, n.1, p. 99–106, 2021.
- MÜLLER, Thomas et al. **Instant neural graphics primitives with a multiresolution hash encoding**. ACM Transactions on Graphics, Jul. 2022.
- SHIN, Seungjoo; PARK, Jaesik. **Binary radiance fields**. ACM Computing Surveys, 2023.
- SUN, Cheng; SUN, Min; CHEN, Hwann-Tzong. **Direct voxel grid optimization:**

Super-fast convergence for radiance fields reconstruction. In: IEEE/CVF CONFERENCE, 2022.

TANCIK, Matthew et al. **Fourier features let networks learn high frequency functions in low dimensional domains.** In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 2020.

WANG, Zhou et al. **Image quality assessment: from error visibility to structural similarity.** IEEE Transactions on Image Processing, 2004.

ZHANG, Richard et al. **The unreasonable effectiveness of deep features as a perceptual metric.** In: IEEE/CVF CONFERENCE, 2018. Edição. Cidade: Editora, Ano de Publicação.

APÊNDICE – Título do Apêndice

ANEXO – Título do Anexo