

TREINAMENTO DE MODELOS NERF BASEADOS EM GRID: UM OLHAR PARA OTIMIZAÇÃO DE HIPERPARÂMETROS: EM HARDWARES DE BAIXA ESPECIFICAÇÃO

TRAINING GRID-BASED NERF MODELS: A LOOK AT HYPERPARAMETER OPTIMIZATION: ON LOW-SPECIFICATION

Luis Afonso Mineo¹
Gustavo Queiroz Silveira²

RESUMO

A técnica de síntese de novas vistas, viabilizada pelos Campos de Radiância Neural (NeRF), representa um avanço significativo na representação de cenas tridimensionais; entretanto, o elevado custo de hardware (em especial de placas de vídeo com grande capacidade de memória) limita sua adoção por pesquisadores e desenvolvedores independentes. Arquiteturas baseadas em grade, como o Instant-NGP, aceleraram o treinamento ao armazenar características da cena em tabelas de hash, porém transferiram o gargalo do processamento para a memória de vídeo (VRAM), criando novo impedimento em hardwares de baixa especificação. Este trabalho tem por objetivo identificar configurações de hiperparâmetros que equilibrem qualidade visual e custo computacional em uma GPU de consumo padrão com 6 GB de VRAM. A justificativa reside na necessidade de popularizar o acesso à tecnologia NeRF, tornando-a viável sem hardware especializado de alto custo. A metodologia divide-se em três etapas: estabelecimento de um baseline com o Instant-NGP em configuração padrão; exploração de hiperparâmetros e análise multiobjetivo. A avaliação comparativa empregará as métricas PSNR, SSIM e LPIPS para qualidade visual, e pico de VRAM, tempo de treinamento para custo computacional. Com isso, o esperado é obter um guia prático de configuração permitindo treinar modelos NeRF de forma eficiente em hardwares acessíveis, sem comprometer drasticamente a fidelidade visual das cenas reconstruídas.

Palavras-chave: campos de radiância neural; síntese de novas vistas; otimização de hiperparâmetros; hardware de baixa especificação

¹ Graduando do Curso de Ciência da Computação do Centro Universitário Filadélfia - UniFil. luismineo@edu.unifil.br

² Orientador: Professor Esp. do curso de Ciência da Computação do Centro Universitário Filadélfia - UniFil. gustavo.silveira@unifil.br

ABSTRACT

Novel view synthesis enabled by Neural Radiance Fields (NeRF) represents a significant advance in three-dimensional scene representation; however, the prohibitive cost of hardware (particularly graphics cards with large video memory) restricts its adoption by researchers and independent developers. Grid-based architectures such as Instant-NGP accelerated training by storing scene features in hash tables, yet shifted the bottleneck from processing power to video memory (VRAM), creating a new barrier on low-specification hardware. This work aims to identify hyperparameter configurations that balance visual quality and computational cost on a consumer-grade GPU with 6 GB of VRAM. The justification lies in the need to popularize access to NeRF technology, making it viable without expensive specialized hardware. The methodology is divided into three stages: establishing a baseline with Instant-NGP in its default configuration; exploring hyperparameters and a multi-objective analysis. Comparative evaluation will use PSNR, SSIM and LPIPS for visual quality, and peak VRAM and training time for computational cost. The expected outcome is a practical configuration guide enabling efficient training of NeRF models on accessible hardware without drastically compromising the visual fidelity of reconstructed scenes.

Keywords: neural radiance fields; novel view synthesis; hyperparameter optimization; low-specification hardware.

1 INTRODUÇÃO

O advento da técnica de síntese de novas vistas, possibilitada pela criação do modelo NeRF (Neural Radiance Fields) (Mildenhall et al., 2021), abriu um novo leque de possibilidades para a representação de cenas tridimensionais. Porém, um dos principais impeditivos para a popularização da técnica entre hobbistas e pesquisadores é o preço proibitivo do hardware necessário para o treinamento do modelo, em especial as placas de vídeo.

A síntese de novas vistas consiste em gerar imagens de uma cena a partir de perspectivas não capturadas originalmente, tendo como entrada apenas um conjunto de fotografias bidimensionais com poses de câmera conhecidas. Abordagens anteriores dependiam de amostragem densa de imagens e de representações geométricas explícitas (malhas poligonais, voxels ou nuvens de pontos), apresentando limitações ao lidar com reflexos, oclusões e superfícies de topologia complexa (Liao et al., 2025). O NeRF substitui essa geometria explícita por

uma representação implícita e contínua, codificada nos próprios pesos de uma rede neural, que mapeia coordenadas espaciais e direções de visão (uma entrada 5D) diretamente em cor e densidade volumétrica; a imagem final é sintetizada por renderização volumétrica diferenciável, acumulando cor e opacidade ao longo dos raios de visão (Mildenhall et al., 2021; Gao et al., 2026).

Os modelos NeRF utilizam-se de Multilayer Perceptrons (MLPs) para o treinamento e renderização das cenas, e para tal, realizam diversos cálculos matriciais, os quais são fortemente dependentes de processamento paralelo (Goodfellow; Bengio; Courville, 2016). As placas de vídeo modernas são altamente especializadas neste tipo de cálculo, além de diversas bibliotecas, como TensorFlow, que foram otimizadas para utilizar este hardware em suas operações (Abadi et al., 2016). Essas redes são treinadas pela minimização de uma função de perda fotométrica, com ajuste iterativo dos pesos por meio do algoritmo de retropropagação em conjunto com otimizadores de gradiente, como o Adam (Kingma; Ba, 2014). Um obstáculo adicional é o viés espectral (*spectral bias*), a tendência de redes neurais aprenderem funções de baixa frequência mais rapidamente do que detalhes finos. O NeRF original contorna essa limitação por meio da codificação posicional com funções de Fourier, que projeta as coordenadas de entrada em um espaço de alta dimensionalidade e viabiliza a captura de alta frequência (Tancik et al., 2020).

Para contornar o longo tempo de processamento exigido pelo modelo original, a indústria e a pesquisa recente migraram para arquiteturas baseadas em grade (Liao et al., 2025). Nessas novas abordagens, as características da cena passam a ser armazenadas explicitamente em estruturas de dados, como tabelas de hash ou voxels (Gao et al., 2026; Shin; Park, 2023). Essa mudança de paradigma tira grande parte da carga de memorização do modelo, permitindo o uso de MLPs bem menores e mais rápidas para calcular as cores e a densidade da imagem (Shin; Park, 2023). Nessas arquiteturas híbridas, a MLP é reduzida a um decodificador mais compacto, essa estratégia, por sua vez, acelerou a convergência de horas para minutos em modelos como Plenoxels (Fridovich-Keil et al., 2022), DVGO (Sun et al., 2022), TensoRF (Chen et al., 2022) e K-Planes (Fridovich-Keil et al., 2023), com resultados superiores a 31 dB de PSNR no dataset Synthetic-NeRF (Gao et al.,

2026). O Instant-NGP (Müller et al., 2022) representa o estado da arte entre esses modelos, no quesito de velocidade, alcançando 33,18 dB em aproximadamente cinco minutos, uma aceleração de até sessenta vezes sobre o NeRF original. Todos esses avanços, contudo, foram avaliados em GPUs de alto desempenho, como a RTX 3090 de 24 GB utilizada nos experimentos originais do Instant-NGP, deixando em aberto a viabilidade dessas arquiteturas em hardware de consumo padrão.

Entretanto, essa evolução veio com um custo. Para ganhar velocidade de renderização, o gargalo passou do poder de processamento para a capacidade de armazenamento (Shin; Park, 2023). A utilização dessas grades associadas a MLPs aumenta o uso de memória de vídeo (VRAM) durante a fase de treinamento, além da geração de arquivos bem maiores no disco após a conclusão do processo. Na prática, isso cria um novo impeditivo para hardwares limitados, causando constantes erros por falta de memória e restringindo novamente a técnica (Liao et al., 2025).

Cabe notar que a literatura de eficiência para NeRF concentra-se majoritariamente na redução de custo durante a inferência, por meio de técnicas como *baking* e super-resolução (Gao et al., 2026; Lin et al., 2024), e não durante o treinamento. Liao et al. (2025) reforçam essa observação ao indicar que o pico de alocação de VRAM na fase de otimização permanece pouco explorado, justamente o ponto em que GPUs mais modestas inviabilizam a execução antes mesmo de produzir qualquer imagem renderizada em *datasets* maiores.

É exatamente neste gargalo que este trabalho se concentra. O presente estudo visa viabilizar o uso dessas tecnologias de síntese de novas vistas em placas de vídeo de consumo padrão. Para atingir isso, a pesquisa buscará encontrar um ponto de equilíbrio ideal otimizando os hiperparâmetros do modelo, limitando as variáveis que mais consomem memória na estrutura de grade e avaliando o impacto dessas reduções. O objetivo final é fornecer um guia prático que possibilite o acesso à criação de NeRFs em hardwares de baixas especificações, permitindo seu treinamento eficiente por desenvolvedores independentes sem comprometer drasticamente a qualidade visual das cenas.

O modelo adotado neste trabalho, o *Instant-NGP* (Müller et al., 2022), substitui a codificação posicional de Fourier por uma hierarquia de tabelas de hash de tamanho fixo distribuídas em diferentes níveis de resolução espacial. O método

mapeia coordenadas 3D, aplica uma função de hash para acessar vetores de características locais, interpola esses valores e concatena o resultado para alimentar uma MLP compacta. As colisões de hash não são tratadas explicitamente: cabe à própria rede desambiguar os pontos sobrepostos, o que se torna viável graças à redundância entre os múltiplos níveis de resolução. Associada a uma implementação em kernels CUDA altamente otimizados (*tiny-cuda-nn*), essa estrutura atinge qualidade foto realista comparável à do NeRF original em poucos minutos (Müller et al., 2022). É essa mesma estrutura, porém, que desloca o gargalo para a memória, onde, variáveis como o tamanho máximo da tabela de hash, a dimensão do vetor de características e o número de níveis tem uma relação direta com o pico de alocação de VRAM durante o treinamento.


A escolha do Instant-NGP como objeto de estudo deste trabalho tem uma observação importante. Desde 2023, o *Gaussian Splatting* Tridimensional (3DGS), introduzido por Kerbl et al. (2023), tornou-se o paradigma dominante para síntese de novas vistas, superando os modelos NeRF em velocidade de renderização e em qualidade visual (Gao et al., 2026). Sua representação é explícita, ou seja, a cena é descrita por um conjunto de primitivas gaussianas 3D que são projetadas no plano da imagem e ordenadas por profundidade em um processo de rasterização denominado *splatting*, dispensando o *ray marching* volumétrico dos NeRFs. O ganho de velocidade, todavia, vem acompanhado de requisitos de VRAM e de armazenamento consideravelmente maiores (Gao et al., 2026), restrições ainda mais severas no hardware de 6 GB considerado nesta pesquisa. Por esse motivo, optou-se pelo modelo híbrido baseado em grade.

2 ESTUDO PRELIMINAR E DEFINIÇÃO DO CENÁRIO EXPERIMENTAL

Inicialmente o trabalho esperava analisar apenas os datasets Lego e Chair, por serem amplamente utilizados na literatura e possuírem características dissidentes, o que, assumia-se ser o suficiente para identificar os valores paramétricos relevantes a ambos os extremos do espectro de modelos. Dado essa premissa, foi realizado o experimento *exp01*, o qual, os resultados, podem ser visto na Figura 1 abaixo, demonstraram que o *Instant-NGP* já se demonstra otimizado,

para *datasets* pequenos. Portanto, a fim de continuar com a experimentação e expandir a busca para *datasets* maiores, os autores decidiram por usar o *dataset Garden*, este, também, amplamente utilizado e considerado padrão ouro na literatura (Gao et al., 2026), inicialmente apresentado através do artigo do *Mip-NeRF 360* (Barron, et al. 2021). *Mip-NeRF 360* reúne cenas reais não-limitadas (*unbounded*), nas quais a câmera circunda um objeto central e o conteúdo de fundo se estende a distâncias mais arbitrárias (Barron et al., 2022). Essa característica amplia a região do espaço que precisa ser amostrada e representada pela estrutura de grade, aumentando assim a pressão sobre a placa de vídeo. A cena *Garden*, especificamente, apresenta geometria complexa e folhagem de alta frequência, o que dificulta a inferência do modelo e acarreta maior consumo de VRAM.

Figura 1 – Gráfico de PSNR por VRAM para o experimento inicial



Fonte: Elaborado pelos autores (2026).

Adicionalmente, a fim de possibilitar uma análise comparativa entre cenas de perfis distintos, mantendo a mesma lógica de contraste geométrico empregada no experimento *exp01* entre as cenas Lego e Chair, optou-se por incluir uma segunda cena do mesmo dataset Mip-NeRF 360: o Bonsai, um ambiente interno, de menor extensão espacial e geometria mais regular, em contraposição à cena externa e

complexa do Garden.

Diferentemente do Synthetic-NeRF, contudo, o dataset Mip-NeRF 360 disponibiliza cada cena em múltiplas resoluções, reduções por fatores de 2, 4 e 8 em relação à resolução original de captura, sem indicar previamente qual delas seria adequada aos propósitos desta pesquisa. Escolher uma resolução arbitrariamente acarretaria no mesmo risco metodológico já identificado no exp01: uma resolução baixa demais poderia novamente não pressionar os 6 GB de VRAM disponíveis, reproduzindo o efeito de teto observado anteriormente; uma resolução alta demais, por sua vez, poderia levar todas as combinações de hiperparâmetros a falhar por esgotamento de memória, inviabilizando a construção da fronteira de Pareto. Fez-se necessária, portanto, uma etapa de calibração prévia à execução do experimento principal.

Essa calibração consistiu em treinar o Instant-NGP em sua configuração padrão, sem variação dos hiperparâmetros de codificação de hash, para cada uma das resoluções disponíveis de cada cena, por um número reduzido de iterações, suficiente apenas para que o pico de alocação de memória fosse atingido. O pico de VRAM de cada execução foi registrado e comparado ao limite físico da GPU utilizada (RTX 2060, 6GB), conforme apresentado na Tabela 1 abaixo. O critério adotado para a escolha da resolução definitiva de cada cena foi selecionar a menor resolução (maior fator de redução) cujo consumo se aproximasse do limite de 6 GB, ou, alternativamente, a resolução imediatamente anterior à primeira ocorrência de falha por falta de memória.

Tabela 1 - Experimento 02 para escolha de resolução

Cena	Fator de Escala	Resolução	Qtd. Imagens	Status	Pico de VRAM (MB)	VRAM Base (MB)	VRAM do Dispositivo (MB)	VRAM na Falha (MB)
garden	8	648x420	185	OK	3477,6	438,6	3916,2	-
garden	4	1297x840	185	OK	4952,6	447,6	5400,2	-
garden	2	2594x1681	185	OOM	4462,6	447,6	4910,2	5918,2
garden	1	-	-	Pulado	-	-	-	-
bonsai	8	390x260	292	OK	2958,6	447,6	3406,2	-
bonsai	4	780x520	292	OK	3906,6	447,6	4354,2	-

bonsai	2 1559x1039	292 OK	5604,6	447,6	6052,2 -	
bonsai	1 3118x2078	292 OOM	5546,6	447,6	5994,2	5921,7

Fonte: Elaborado pelos autores, 2026

Paralelamente, foi necessário determinar o valor do parâmetro ***aabb_scale*** para cada cena. Esse parâmetro define a extensão espacial da caixa dentro da qual o modelo assume que toda a cena pode ser representada, sendo estruturado como uma cascata de grades de ocupação multiescala (Müller et al., 2022). Diferentemente do Synthetic-NeRF, cujas cenas são objetos isolados contidos em um cubo unitário (*aabb_scale* = 1), cenas reais e não-limitadas, como as do Mip-NeRF 360, exigem valores mais altos, de modo a acomodar elementos de fundo que se estendem além do objeto central, caso contrário, o modelo tende a alucinar *floaters* (artefatos visuais “flutuantes”) nas bordas da caixa delimitadora. A documentação oficial da implementação orienta que o valor seja sempre uma potência de dois e recomenda, para cenas naturais, que se inicie a partir de um valor elevado e reduza-o progressivamente por fatores de dois até que a qualidade da reconstrução seja considerada adequada (NVLABS, 2025). Seguindo essa orientação, ambas as cenas foram inicialmente configuradas com ***aabb_scale* = 16**, sendo então submetidas a uma verificação empírica: treinamentos breves foram realizados para valores candidatos, com inspeção das imagens renderizadas em busca de artefatos característicos de uma caixa delimitadora subdimensionada, manchas ou névoa próximas às bordas da reconstrução, indicando conteúdo de fundo não contemplado pela caixa, além da verificação mais objetiva por cálculo de *PSNR*. Os resultados dessa verificação estão descritos na Seção 2.1, e determinaram o valor de ***aabb_scale*** efetivamente utilizado na etapa seguinte do experimento.

2.1 CALIBRAÇÃO DO DATASET

A calibração do fator *aabb_scale* foi realizada através de uma verificação visual dos resultados, além da verificação mais objetiva por cálculo do *PSNR* (*Peak Signal-to-Noise Ratio*), métrica que relaciona o valor máximo possível de um pixel ao erro quadrático médio da reconstrução e que constitui o padrão consolidado de

avaliação de fidelidade de imagem (Wang et al., 2004). Na Figura 2, abaixo, podemos notar que o fator 4 e 8 são os melhores candidatos visuais.


Figura 2 – Comparação visual da cena *Garden* para fatores de 2 a 32



Fonte: Elaborado pelos autores (2026).

Como podemos notar, o fator 2 e 16 apresentam diversos artefatos neste ângulo, que prejudicam a visualização da cena, o que, curiosamente, contradiz a recomendação inicial dos autores do *Instant-NGP*. Essa rodada de testes, também capturou os valores de *PSNR* e revelou que, o fator 4 se confirma como o melhor candidato através do cálculo de fidelidade visual, ainda mantendo um pico de alocação de memória baixo, observado na Figura 3.

Figura 3 – Gráfico comparativo para o fato de *aabb_scale*



Fonte: Elaborado pelos autores (2026).

3 METODOLOGIA

Após a escolha e calibragem do novo dataset, partimos para a experimentação em si. O experimento deste trabalho estrutura-se em 4 etapas: a definição do baseline, a exploração sistemática de hiperparâmetros, a análise multiobjetivo dos resultados e, por fim, a avaliação das métricas encontradas. A lógica que organiza essas etapas é a de estabelecer primeiro um limite superior de qualidade (o comportamento do modelo em sua configuração padrão) e, a partir dele, medir o quanto de memória é possível economizar e qual o custo disso em fidelidade visual. Esta seção descreve o ambiente experimental e detalha cada uma das etapas.

3.1 AMBIENTE EXPERIMENTAL

O ambiente utilizado para este experimento foi uma GPU Nvidia RTX 2060 com 6GB de memória de vídeo (VRAM), uma CPU Ryzen 7 7700 X3D e 16 GB de RAM DDR4, tudo executado dentro de um ambiente WSL (*Windows Subsystem for Linux*) com ubuntu.

3.2 DEFINIÇÃO DO BASELINE

O baseline consiste no treinamento do Instant-NGP em sua configuração padrão, arquivo de rede (*base.json*) sem qualquer alteração nos hiperparâmetros de codificação de hash (Müller et al., 2022), aplicado a cada uma das duas cenas, na resolução e no *aabb_scale* definidos na etapa de calibração (Seção 2.1). Para a cena Garden, adotou-se o fator de redução X (XXXXxYYYY pixels) [a confirmar ainda] e *aabb_scale* = 4; para a cena Bonsai, adotou-se o fator de redução 2 (1559x1039 pixels) e *aabb_scale* = [a confirmar ainda], seguindo o mesmo critério de seleção descrito na Seção 2.

Diferentemente do *exp01*, no qual o dataset Synthetic-NeRF já disponibiliza uma divisão oficial entre conjuntos de treino e teste, o dataset Mip-NeRF 360 não oferece tal separação. Adotou-se, portanto, a convenção consolidada na literatura para cenas reais, na qual uma a cada oito imagens é reservada para o conjunto de

teste e as demais compõem o conjunto de treino, procedimento estabelecido no LLFF (Mildenhall et al., 2019) e mantido na avaliação do próprio *Mip-NeRF* 360 (Barron et al., 2022), regra assim, aplicada de forma idêntica a todas as execuções de ambas as cenas. Por se tratar de cenas não-limitadas, desabilitou-se também o modo de compatibilidade com o protocolo do NeRF original (*nerf_compatibility*), adequado ao Synthetic-NeRF mas não aos datasets reais utilizados nesta etapa.

O número de iterações de treinamento foi definido em [N], valor obtido por meio de uma validação específica da curva de convergência para cenas não-limitadas (Figura X <TODO>), em procedimento análogo ao realizado para a cena Lego no projeto original. A verificação fez-se necessária porque cenas reais tendem a apresentar uma convergência mais lenta do que cenas sintéticas, tornando inadequada a reutilização direta do número de iterações anteriormente adotado. Vale lembrar que, na implementação original, o marco de 20.000 passos corresponde ao ponto em que ocorre a primeira penalização da taxa de aprendizado (*learning rate decay*), o que o torna um ponto de parada metodologicamente defensável desde que sustentado pela curva de perda observada (Müller et al., 2022).

O objetivo desta etapa é estabelecer um limite superior de qualidade visual e um ponto de referência de custo computacional para cada cena, contra os quais as configurações exploradas na etapa seguinte serão comparadas.

3.3 EXPLORAÇÃO SISTEMÁTICA DOS HIPERPARÂMETROS

Na etapa seguinte, aplicou-se novamente o método de Busca em Grade (Grid Search) já empregado no exp01, mantendo o mesmo espaço de busca sobre os três hiperparâmetros da codificação de hash multirresolução: *log2_hashmap_size* ($T \in \{15, 17, 19\}$), *n_features_per_level* ($F \in \{2, 4, 8\}$) e *n_levels* ($L \in \{4, 8, 16\}$), totalizando 27 combinações por cena. A escolha da Busca em Grade justifica-se pelas características do espaço explorado. Bergstra e Bengio (2012), ao proporem a busca aleatória como alternativa, reconhecem que o *Grid Search* permanece confiável em espaços de baixa dimensionalidade e que, em espaços reduzidos com execução sequencial, pode superar o *Random Search*. Com apenas três hiperparâmetros e 27 combinações por cena, o espaço desta pesquisa enquadra-se

nesse campo favorável, somando-se a isso a garantia de cobertura completa e de reprodutibilidade do experimento.

A resolução e o *aabb_scale* de cada cena permaneceram fixos nos valores definidos na etapa de calibração e replicados na definição do baseline (Seção 3.2), variando-se exclusivamente os três hiperparâmetros de codificação. Estes, por sua vez, atuam diretamente sobre o volume de memória alocado pela codificação de hash. O expoente do tamanho máximo de cada tabela (T), a dimensão do vetor de características armazenado em cada entrada (F) e o número de níveis de resolução (L) determinam o limite superior do número de parâmetros da estrutura de grade, proporcional a $L \cdot 2^T \cdot F$ (Müller et al., 2022); reduções em qualquer um dos três implicam, portanto, redução proporcional no consumo de VRAM. Müller et al. (2022) fixam $L = 16$, $T = 19$ e $F = 2$ como configuração padrão, valores que correspondem exatamente ao vértice superior do espaço de busca aqui adotado e, consequentemente, ao *baseline* descrito na Seção 3.2.

A manutenção do mesmo espaço de busca do *exp01* é proposital, pois permite que os efeitos observados em cada hiperparâmetro sejam comparáveis, em relativamente, entre a de cena limitada (*Synthetic-NeRF*) e o de cena não-limitada (*Mip-NeRF 360*), ainda que os valores absolutos de PSNR não sejam diretamente comparáveis entre os dois experimentos, dado que os protocolos de avaliação, a divisão de dados e a natureza das cenas diferem.

Para cada combinação, foram registradas as mesmas cinco métricas coletadas no *exp01*: PSNR, SSIM e LPIPS, como medidas de qualidade de reconstrução visual, e pico de alocação de VRAM e tempo de treinamento, como medidas de custo computacional. Diferentemente do *exp01*, no qual nenhuma das 54 execuções resultou em falha por falta de memória, esperava-se, dada a calibração realizada na Seção 2, que uma parcela das combinações desta etapa pudesse exceder os 6 GB de VRAM disponíveis. Execuções nessas condições não foram descartadas: o status de cada execução foi registrado como resultado válido, uma vez que o mapeamento das combinações inviáveis representam uma informação relevante para a análise multiobjetivo subsequente.

Os resultados desta etapa, para as cenas Garden e Bonsai, estão apresentados na Tabela Y e na Figura X.

<TODO - Inserir Tabela com resultados do grid>

<TODO - Inserir Figura com curva de convergência>

3.4 ANÁLISE MULTIOBJETIVO DOS RESULTADOS

A Fronteira de Pareto é o instrumento consolidado da otimização multiobjetivo para mapear permutas (*trade-offs*) entre critérios conflitantes. Assumimos que uma configuração domina outra quando é ao menos tão boa em todos os objetivos e estritamente melhor em pelo menos um deles; o conjunto das soluções não dominadas define a fronteira na qual qualquer ganho em um objetivo implica necessariamente sacrifício em outro (Deb, 2011). A vantagem dessa abordagem, no contexto desta pesquisa, é permitir a identificação do ponto de equilíbrio (*sweet spot*) entre fidelidade visual e custo computacional sem que seja preciso arbitrar previamente uma ponderação entre os critérios.

Os resultados do Grid Search completo foram submetidos à mesma análise multiobjetivo fundamentada na Fronteira de Pareto empregada no *exp01*, na qual uma configuração é considerada não dominada quando nenhuma outra configuração é simultaneamente igual ou superior em todos os objetivos e estritamente superior em ao menos um deles. Os três objetivos considerados foram: maximizar o PSNR, minimizar o pico de alocação de VRAM e minimizar o tempo de treinamento.

A fronteira foi calculada separadamente para cada cena, permitindo avaliar se as configurações identificadas como não dominadas se sustentam em perfis de cena distintos, um externo, com vegetação e geometria complexa, e outro interno, com geometria mais regular e menor extensão espacial (*Garden* e *Bonsai*, respectivamente), na mesma lógica de validação externa empregada entre as cenas Lego e Chair no *exp01*.

Optou-se por apresentar como resultado principal a projeção bidimensional entre PSNR e pico de VRAM, e não a fronteira tridimensional completa. Essa escolha decorre da observação, já registrada no *exp01*, de que a fronteira tridimensional tende a ser pouco clara, quando os três objetivos são considerados simultaneamente, ao passo que a projeção bidimensional evidencia com mais clareza o comportamento entre qualidade visual e custo de memória.

3.5 AVALIAÇÃO DAS MÉTRICAS

A avaliação comparativa entre o baseline e as configurações do Grid Search seguiu a mesma estrutura de duas categorias adotada no exp01. Para o custo computacional, foram registrados o pico de alocação de VRAM, em megabytes, e o tempo total de treinamento, em segundos. Para a qualidade de reconstrução visual, empregaram-se as três métricas complementares já utilizadas anteriormente: o PSNR, medido em decibéis, que relaciona o valor máximo possível de um pixel ao erro quadrático médio (MSE) da reconstrução e é amplamente adotado por sua simplicidade de cálculo e por suas propriedades matemáticas bem definidas, ainda que não reflita perfeitamente a percepção visual humana, imagens com o mesmo PSNR podem apresentar qualidades perceptuais distintas (Wang et al., 2004); o SSIM, que avalia a imagem a partir de luminância, contraste e estrutura, capturando texturas e bordas de forma mais alinhada à percepção humana e sendo particularmente sensível a desfoque e a artefatos como *floaters* e perda de nitidez (Wang et al., 2004); e o LPIPS, calculado com a rede *AlexNet*, que compara imagens por meio das representações internas de redes neurais pré-treinadas, partindo da ideia de que essas redes capturam padrões perceptuais inacessíveis a métricas calculadas apenas sobre pixels (Zhang et al., 2018). Diferentemente das duas primeiras, o LPIPS é uma métrica de distância, na qual valores menores indicam maior similaridade, o que o torna eficaz para detectar artefatos de alta frequência, como o ruído granular produzido por colisões de hash. O uso conjunto das três (fidelidade global, estrutura local e similaridade perceptual) é uma prática consolidada na literatura de NeRF (Mildenhall et al., 2021) e garante uma avaliação mais completa do que qualquer uma delas isoladamente.

A degradação de cada configuração em relação ao respectivo baseline foi expressa em variação percentual de VRAM e tempo de treinamento, e em variação absoluta de PSNR (em decibéis), permitindo identificar, para cada cena, o conjunto de configurações cuja degradação de qualidade permaneceu dentro do limiar de -2 dB considerado aceitável na literatura (Mildenhall et al., 2021; Müller et al., 2022). Os resultados dessa avaliação, incluindo a comparação entre os regimes de cena limitada e não-limitada quanto à magnitude dos efeitos observados para cada hiperparâmetro, são apresentados e discutidos na Seção 4.

4 ANÁLISE DOS RESULTADOS

<TODO>

5 CONCLUSÃO

<TODO>

REFERÊNCIAS

- DEB, Kalyanmoy. **Multi-objective optimization using evolutionary algorithms: an introduction**. Kanpur: Indian Institute of Technology Kanpur, 2011. (KanGAL Report Number 2011003).
- DESCARTES, René. **Discurso do método**. Tradução de Maria Ermantina Galvão. 2. ed. São Paulo: Martins Fontes, 2001.
- FOLEY, James D. et al. **Computer graphics: principles and practice**. 2nd ed. Reading: Addison-Wesley, 1996.
- FRIDOVICH-KEIL, Sara et al. **K-Planes: Explicit radiance fields in space, time, and appearance**. arXiv:2301.10241, 2023.
- FRIDOVICH-KEIL, Sara et al. **Plenoxels: Radiance fields without neural networks**. In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2022.
- GAO, Kyle et al. **NeRF: Neural radiance field in 3D vision, a comprehensive review**. Computational Visual Media, [S. l.], 2026.
- GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep learning**. Cambridge: MIT Press, 2016.
- KERBL, Bernhard et al. **3D Gaussian Splatting for real-time radiance field rendering**. ACM Transactions on Graphics, v. 42, n. 4, p. 193:1–193:14, 2023.
- KINGMA, Diederik P.; BA, Jimmy. Adam: **A method for stochastic optimization**. arXiv:1412.6980, 2014.
- LIAO, Yun et al. **A survey on neural radiance fields**. ACM Computing Surveys, [S. l.], v. 58, n. 2, 2025.
- LIN, Chen-Yu et al. **FastSR-NeRF: improving NeRF efficiency on consumer devices with a simple super-resolution pipeline**. In: IEEE/CVF WINTER CONFERENCE ON APPLICATIONS OF COMPUTER VISION, 2024. p. 6036–6045.
- MILDENHALL, B; SRINIVASAN, P.; TANI, M.; BARRON, J.; RAMAMOORTHY, R.; NG, R.. **NeRF: representing scenes as neural radiance fields for view synthesis**. Commun. ACM, v.65, n.1, p. 99–106, 2021.
- MÜLLER, Thomas et al. **Instant neural graphics primitives with a multiresolution hash encoding**. ACM Transactions on Graphics, Jul. 2022.
- SHIN, Seungjoo; PARK, Jaesik. **Binary radiance fields**. ACM Computing Surveys, 2023.
- SUN, Cheng; SUN, Min; CHEN, Hwann-Tzong. **Direct voxel grid optimization:**

Super-fast convergence for radiance fields reconstruction. In: IEEE/CVF CONFERENCE, 2022.

TANCIK, Matthew et al. **Fourier features let networks learn high frequency functions in low dimensional domains.** In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 2020.

WANG, Zhou et al. **Image quality assessment: from error visibility to structural similarity.** IEEE Transactions on Image Processing, 2004.

ZHANG, Richard et al. **The unreasonable effectiveness of deep features as a perceptual metric.** In: IEEE/CVF CONFERENCE, 2018. Edição. Cidade: Editora, Ano de Publicação.

APÊNDICE – Título do Apêndice

ANEXO – Título do Anexo